# FINAL REPORT ON CREDIT RISK MODEL IN R/PYTHON 2023

Subject: Forecasting credit repayment ability of customers

Study program: K20414C\_Fintech

Class ID: 222CN1001

Student: Nguyễn Văn Thành

ТТ	Full name	Student code	Class	Role	Phone number	Email
1.	Nguyễn Văn Thành	K204140640	K20414 C	Thành viên	0343984998	Thanhnv20414 c@st.uel.edu.vn
2.						
3.						
4.						
5.						

# HO CHI MINH CITY NATIONAL UNIVERSITY UNIVERSITY OF LAW AND ECONOMICS

# FINAL REPORT ON CREDIT RISK MODEL IN R/PYTHON 2023

Subject: Forecasting credit repayment ability of customers

# **ASSURANCE**

I hereby declare that the report "Forecasting credit repayment ability of customers" is the result of my work under the guidance of TS. Pham Thi Thanh Xuan, within the framework of the module "Credit Risk Modeling in R/Python".

# Contents

LIST OF TABLES	2
LIBRARIES USED IN THE REPORT	3
I. Introduction	5
1.1. Request	5
1.2. Models and tools used in the report	5
1.3. Data Description	6
1.4. The process	7
II. Content	8
2.1. Step 1: Import data	8
2.2. Step 2: Transform data	9
2.3. Step 3: Check the data	10
2.3.1. Missing data	10
2.3.2. Abnormal data	10
2.3.3. Check outliers data	12
2.4. Step 4: Descriptive Statistics	14
2.4.1. Statistical index	14
2.4.2. The degree of correlation between variables	15
2.5. Step 5: Visualization	16
2.5.1. Data distribution of quantitative variables	16
2.5.2. Visualize layered data and target variables	17
2.5.3. Visualize the amount of data in the observed variables	
2.6. Step 6: Prepare data for the model	20
2.6.1. Check target variable	20
2.6.2. Prepare data for the model	21
2.7. Step 7: Run and read model results with Decision Tree	22
2.7.1. Compare Decision Tree results with unbalanced and unbalanced data	22

2.7.2. Important variables for Decision Tree	25
2.7.3. Decision Tree's ROC_Curve	26
2.7.4. Plot tree	28
2.8. Step 8: Run and read model results with Random Forest	
2.8.1. Run and read model results with Random Forest	
2.8.2. Important variables with Random Forest	
2.8.3. Random Forest's ROC_Curve	
2.9. Step 9: New customer forecast with used data set	34
III. Conclusion.	35
Github:	39
Reference documents	39
LIST OF TABLES	
Table 1_ 2.1. Load data	
Table 2 Code box result table 2.1:: Load data	
Table 3_ Code box 2.2. Transform data	
Table 4 Code box result table 2.2. Data conversion	
Table 5 Code box 2.3. Check for missing data	
Table 6 Code box result table 2.3: Check for missing data	
Table 7 Code box 2.4. Check for invalid data	
Table 8 Code box results box 2.4: Check invalid data	
Table 9 Code box 2.5. Get valid data  Table 10 Code box result box 2.5: Get valid data	
Table 10 Code box result box 2.5. Get valid data	
Table 12 Result table of code box 2.6: Check outlier data	
Table 13 Code box 2.7. Statistical index	
Table 14 Code box result table 2.7: Statistical index	
Table 15 Code box 2.8. Check the degree of correlation between variables	
Table 16 Code box result table 2.8: Check the degree of correlation between variables	
Table 17 Code box 2.9. Data distribution	
Table 18 Code box result table 2.9: Data distribution	
Table 19 Code box 2.10. Checking customer's ability to repay debt by gender	
Table 20 Code box result table 2.10: Checking customer's ability to repay debt by gender	
Table 21 Code box 2.11. Amount of data in observed variables	
Table 22 Code box result table 2.11: Number of data in observed variables	
Table 23 Code box 2.12. Check target variable	
Table 24 Code result table 2.12: Check target variable	
Table 25 Code box 2.13. Data balance	21

Table 26 Code box result table 2.13: Data balance	21
Table 27 Code box result table 2.14. Prepare forecast data for the model	21
Table 28 Code box 2.15: Normalize data	22
Table 29 Code box 2.16. Run and read model results with Decision Tree (unbalanced data)	22
Table 30 Code box results table 2.16: Run and read model results with Decision Tree	23
Table 31 Code box 2.17. Run and read model results with Decision Tree (balanced data)	23
Table 32 Code box results table 2.17: Run and read model results with Decision Tree	24
Table 33 Table 2.1: Comparing the results of Decision Tree on 2 data sets	24
Table 34 Code box 2.18. Find variables with strong influence on Decision Tree	25
Table 35 Code box results table 2.18: Run and read model results with Decision Tree	26
Table 36 Code box 2.19. Plot Decision Tree's ROC_Curve	26
Table 37 Code box result table 2.19: Plot Decision Tree's ROC_Curve	27
Table 38 Code box 2.20. Plot Tree	28
Table 39 Code box result table 2.20: Plot Tree	28
Table 40 Code box 2.21. Run and read forecasts with Random Forest	30
Table 41 Code box result table 2.21: Run and read forecast results with Random Forest	31
Table 42 Code box 2.22. Important Variables Random Forest	32
Table 43 Code box results table 2.22: Important Variables Random Forest	32
Table 44 Code box 2.23. Random Forest's ROC_Curve	33
Table 45 Code box results table 2.23: Code box 2.23. Random Forest's ROC_Curve	33
Table 46 Code box 2.24. Generate new customer data and forecasts	34
Table 47 Code box results table 2.23: Run and read forecast results with Random Forest	34
Table 48 Code box 3.1. Compare indicators between 2 forecasting models	35
Table 49 Code box results table 3.1: Compare the stability of the forecast results	36
LIST OF CHARTS	
Figure 1 Process	
Figure 2 Chart 2.1. Name the branches in the tree	29

## LIBRARIES USED IN THE REPORT

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from six import StringIO
from IPython.display import Image
from sklearn.tree import export_graphviz
import pydotplus
from sklearn.tree import plot_tree
from sklearn.utils import resample
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix
from sklearn.preprocessing import LabelEncoder, StandardScaler
from sklearn.model_selection import cross_val_score, KFold, cross_validate,
cross val predict
from sklearn.metrics import classification_report, f1_score, precision_score,
recall_score, accuracy_score
from sklearn.linear model import LogisticRegression
from sklearn.neighbors import KNeighborsClassifier
from sklearn.naive_bayes import GaussianNB
from sklearn.svm import SVC
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier, GradientBoostingClassifier,
AdaBoostClassifier, BaggingClassifier
from sklearn.neural network import MLPClassifier
from xgboost import XGBClassifier
from catboost import CatBoostClassifier
from lightgbm import LGBMClassifier
import time
```

#### I. Introduction

## 1.1. Request

Building a model to predict the creditworthiness of customers using Decision Tree and Random Forest based on the data provided in the class "Credit risk modeling in R/Python".

#### 1.2. Models and tools used in the report

The main tool used in the report is Python used in the Visual Studio Code environment, in addition, Excel and Word are supporting tools to view data and write reports.

The model used in the report is Decision Tree and Random Forest will be the model selected as the matching tool.

Decision Tree is a key tool in predicting the creditworthiness of customers because it can classify customers into groups based on their characteristics, helping to make predictions about the repayment capacity of customers. customers become easier. The Decision Tree can also display the different decisions and choices that lead to the predicted outcome, making it easier for users to understand and interpret. In addition, Decision Tree allows to add new rules or modify existing rules easily, making the forecasting process more flexible and efficient in improving prediction accuracy.

Random Forest was chosen as a tool to match Decision Tree in predicting credit solvency of customers because it has many advantages compared to Decision Tree. While Decision Trees can be prone to overfitting and cannot generalize to data, Random Forest uses multiple decision trees to create a predictive model, which minimizes the effect of noise and increases the generality of the model. Decision trees in Random Forest are built on sub-data sets, which helps to avoid overfitting and increase the generality of the model. In addition, Random Forest also allows to calculate the importance of features, helping users to understand which features are important in predicting the repayment ability of customers. Finally, Random Forest has high accuracy and good predictability, helping users to make more accurate and effective decisions than Decision Tree.

## 1.3. Data Description

Target variable: "Khả năng trả nọ", where 0: is a customer paying on time, 1 is a customer not paying on time.

Variable 1: 'ID khách hàng', provide customer code.

Variable 2: 'Giới tính', 1: male, 0: female.

Variable 3: 'Quốc tịch', 1: Việt Nam, 2: Foreign.

Variable 4: 'Hóa đơn tiền điện', showing the amount of electricity to be paid by the customer.

Variable 5: 'Số tiền vay', represents the customer's loan amount.

Variable 6: 'Muc đích vay', represents the customer's loan purpose. Where 1: is for consumption,

2: is to buy a house, 3: is to buy a car, 4: is to study, 5: is to invest in securities.

Variable 7: 'Gia đình', shows the marital status of the client. Where 1: Married, 2: Single, 3: Divorced.

Variable 8: 'Thời gian tại công việc hiện tại', where 1: is 1 year, 2: is 2 years, 3: is 3 years, 4: is 4 years, 5: is more than 5 years.

Variable 9: 'Tuổi', shows the age of the customer.

Vaiable 10: 'Tài sản đảm bảo', where 0: is not owned by the borrower, 1: is owned by the borrower.

Variable 11: 'No xấu', where 0: is no bad debt, 1: is bad debt.

Variable 12: 'Khoảng cách đến điểm giao dịch', in km, showing the customer's distance to the nearest transaction point. Where 1: is less than 10km, 2: is from 10 to 20 km, 3: is from 20 to 30 km, 4 is more than 30 km.

Variable 13: 'Học vấn', showing the level of education of the customer. Where 1: is a graduate school, 2: is a university, 3: is a high school, 4: is other.

Variable 14: 'Thời gian vay', in monthly, showing the loan period of the customer.

## 1.4. The process

Chart 1.1. Process

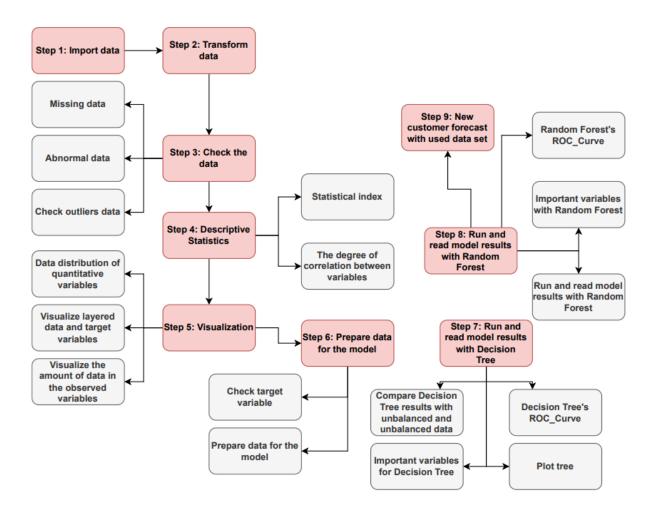


Figure 1 Process

# II. Content

# 2.1. Step 1: Import data

## Code box 2.1. Load data

Table 1\_ 2.1. Load data

```
# Read the data and display the first 5 lines:

df = pd.read_excel('test.xlsx')

df.head()

# Check information and data format:

df.info()
```

# Code box results table 2.1: Load data

Table 2 Code box result table 2.1:: Load data

				tại		bảo		nhất ( km )		vay (tháng)	trả nợ
Việt 61000 Nam	0 600000000	2. mua nhà	1. Đã kết hôn	3. 3 năm	30	1. Thuộc sở hữu người vay	0. Không có nợ xấu	1. x<10	4. Khác	12	0. Trả nợ đúng hạn
	0 50000000	4. học tập	2. Độc thân	1. 1 năm	23	0. Không thuộc sở hữu người vay	0. Không có nợ xấu	2. 10 <x<20< td=""><td>2. Đại học</td><td>6</td><td>0. Trả nợ đúng hạn</td></x<20<>	2. Đại học	6	0. Trả nợ đúng hạn
	0 200000000	3. mua xe	2. Độc thân	2. 2 năm	28	1. Thuộc sở hữu người vay	0. Không có nợ xấu	3. 20 <x<30< td=""><td>3. Trung học phổ thông</td><td>10</td><td>0. Trả nợ đúng hạn</td></x<30<>	3. Trung học phổ thông	10	0. Trả nợ đúng hạn
	0 150000000	5. đầu tư chứng khoán	1. Đã kết hôn	5. Trên 5 năm	32	1. Thuộc sở hữu người vay	0. Không có nợ xấu	3. 20 <x<30< td=""><td>1. Cao học</td><td>12</td><td>0. Trả ng đúng hạr</td></x<30<>	1. Cao học	12	0. Trả ng đúng hạr
	0 300000000	3. mua xe	2. Độc thân	1. 1 năm	17	0. Không thuộc sở hữu người vay	1. Có nợ xấu	3. 20 <x<30< td=""><td>4. Khác</td><td>4</td><td>1. Không trả nọ đúng hạr</td></x<30<>	4. Khác	4	1. Không trả nọ đúng hạr
1 (2 (3 ) 4 (5 ) 6 (6 ) 7 (7 ) 8 (7 ) 9 (11 ) 11 (12 ) 13 (13 )	Giới tính Quốc tịch Hóa đơn ti Số tiền va Mục đích v Gia đình Thời gian Tuổi Tài sản đả Nợ xấu Học vấn	ền điện y ay tại công m bảo h đến đi vay (thá	ểm giad		n nh	ất ( km )	3000 3000 3000 3000 3000 3000 3000 300	non-null obj non-null int non-null int non-null obj non-null obj non-null obj non-null int non-null obj non-null obj non-null obj non-null obj non-null obj non-null obj	ect ect 64 64 ect ect ect ect ect ect ect ect		
nữ 2. N nữ nọ nữ 1. 1.	Nam  nữ 2. Nước ngoài 30000  nữ 1. Việt Nam 70000  1. 1. Việt Nam 14000  < class Range: Data (1) 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1	nα         2. Nước ngoài         300000         200000000           nα         1. Việt Nam         700000         150000000           1. 1. Việt am         140000         300000000 <class 'pandas.="" 300<="" rangeindex:="" td="">         300           Data columns (t         # Column           0 ID khách h         1 Giới tính           2 Quốc tịch         3 Hóa đơn ti           4 Số tiền va         5 Mục đích v           6 Gia đình         7 Thời gian           8 Tuổi         9 Tài sản đả           10 Nợ xấu         11 Khoảng các           12 Học vấn         13 Thời gian</class>	nữ 2. Nước ngoài 300000 200000000 3. mua xe  1. Việt Nam 700000 150000000 5. đầu từ chứng khoán  1. 1. Việt Nam 140000 300000000 3. mua xe  (class 'pandas.core.fra RangeIndex: 3000 entrie Data columns (total 15 # Column	nữ         1. Việt Nam         150000         50000000         4. học tập         2. Độc thần           nữ         2. Nước ngoài         300000         200000000         3. mua xe         2. Độc thần           nữ         1. Việt Nam         700000         150000000         5. đầu tư chứng kết hón         1. Đã chứng kết hón           1.         1. Việt Nam         140000         300000000         3. mua xe         2. Độc thần           2.         Calass 'pandas.core.frame.Data RangeIndex: 3000 entries, 0 to Data columns (total 15 columns de Columns)         4. Column         4. Column	nữ         1.Việt Nam         150000         50000000         4. học tập         2. Độc thấn         1.1 năm           nữ         2. Nước ngoài         300000         200000000         3. mua xe         2. Độc thấn         2. 2 năm           nữ         1. Việt Nam         700000         150000000         5. đầu tư chứng khoán         1. Đặc kết hốn         5. Trên 5 năm           1.         1. Việt Nam         140000         300000000         3. mua xe         2. Độc thấn         1.1 năm            class 'pandas.core.frame.DataFrame'> RangeIndex: 3000 entries, 0 to 2999         Data columns (total 15 columns):         # Column          0         ID khách hàng         1 Giới tính         2 Quốc tịch         3 Hóa đơn tiền điện           4         Số tiền vay         5 Mục đích vay         6 Gia đình         7 Thời gian tại công việc hiện tại           7         Thời gian tại công cách đếm điểm giao dịch gầ         12 Học vấn         13 Thời gian vay (tháng)	nữ         1.Việt Nam         150000         50000000         4. học tập         2. Độc thấn         1.1 năm         23           nữ         2. Nước ngoài         300000         20000000         3. mua xe         2. Độc thấn         2.2 năm         28           nữ         1. Việt Nam         700000         150000000         5. đãu tư chứng kết hốn         5. Trên 5 năm         32           1.         1. Việt Nam         140000         300000000         3. mua xe         2. Độc thấn         1.1 năm         17            Class 'pandas.core.frame.DataFrame'> RangeIndex: 3000 entries, 0 to 2999         Data columns (total 15 columns):         # Column         —————         0 ID khách hàng         1 Giới tính         2 Quốc tịch         3 Hóa đơn tiền điện         4 Số tiền vay         5 Mục đích vay         6 Gia đình         7 Thời gian tại công việc hiện tại         8 Tuổi         9 Tài sản đảm bảo         10 Nợ xấu         11 Khoảng cách đến điểm giao dịch gần nh         12 Học vấn         13 Thời gian vay (tháng)	nữ         1.Việt Nam         150000         50000000         4. học tập         2. Độc thắn         1.1 năm         23         thuộc sở hữu người vày           nữ         2. Nước ngoài         300000         200000000         3. mua xe         2. Độc thắn         2. 2 năm         28         hữu người vày           nữ         1. Việt Nam         700000         150000000         5. đầu tư         1. Đã thán         5. Trên 5 năm         32         1. Thuộc sở hữu người vày           1.         1. Việt Nam         140000         300000000         3. mua xe         2. Độc thắn         1.1 năm         17         thuộc sở hữu người vày           1.         1. Việt Nam         140000         300000000         3. mua xe         2. Độc thán         1.1 năm         17         thuộc sở hữu người vày           1.         1. Việt Nam         140000         300000000         3. mua xe         2. Độc thán         1.1 năm         17         thuộc sở hữu người vày           2.         1. 1. Việt Nam         140000         300000000         3. mua xe         2. Độc thán         1.1 năm         17         thuộc sở hữu người vày           3.         1. Niệt San thán tháng         1. Số tiến vày         6         1. 1 năm         17         thuộc sở hữu người vày	nữ         1.Việt Nam         150000         5000000         4. học tập         2. Độc thấn         1.1 năm         23         0. Không thuộc sở hữu người vay         0. Không có ng xấu           nữ         2. Nước ngoài         30000         20000000         3. mua xe         2. Độc thấn         2. 2 năm         28         hữu người vay         0. Không có ng xấu           nữ         1. Việt Nam         700000         150000000         5. đầu tư         1. Đã kết thấn         5. Trên 5 nắm         32         hữu người vay         0. Không có ng xấu           1. 1. Việt Am         140000         300000000         3. mua xe         2. Độc thấn         1. 1 năm         17         thúng sối ng xấu         0. Không có ng xấu           2. Việt Nam         70000         150000000         3. mua xe         2. Độc thấn         1. 1 năm         17         thúng sối ng xấu         0. Không có ng xấu           1. Việt Am         70000         150000000         3. mua xe         2. Độc thất         1. 1 năm         17         thúng sối ng xấu         0. Không thúng sối ng xấu         1. Cống xấu         1. Thuộc sởi hữu người vay         1. Cống xấu         1	1. Việt Nam   150000   50000000   4. học tập   2. Độc thần   1. 1 năm   23 thước số hữu người vày có nơ xấu   2. 10 < x < 20 cón dà xấu   2. 10 < x < 20 cón dà xấu   2. 10 < x < 20 cón dà xấu   2. 10 < x < 20 cón dà xấu   2. 10 < x < 20 cón dà xấu   2. 10 < x < 20 cón dà xấu   2. 10 < x < 20 cón dà xấu   2. 10 < x < 20 cón dà xấu   2. 10 < x < 20 cón dà xấu   2. 10 < x < 20 cón dà xấu   2. 10 < x < 20 cón dà xấu   2. 10 < x < 20 cón dà xấu   2. 10 < x < 20 cón dà xấu   2. 10 < x < 20 cón dà xấu   2. 10 < x < 20 cón dà xấu   2. 10 < x < 20 cón dà xấu   2. 10 < x < 20 cón dà xấu   2. 10 < x < 20 cón dà xấu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xấu   2. 10 < x < 20 cón dà xấu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2. 10 < x < 20 cón dà xáu   2	1. Việt Nam 150000 5000000 4. học tập 2. Độc thần 1. 1 năm 23 được sở hõu gó nợ xấu 2. 10 cx < 20 2. Đại học ngoài 30000 20000000 3. mua xe 2. Độc thần 2. 2 năm 28 hữu người vay	1. Việt Nam 150000 50000000 4. học tập 2. Độc thần 1.1 năm 23 thuộc số hữu người vày có nợ xấu 2.10         0. Không nợ xấu 2.10         0. Không nợ xấu 2.10         2. Đại học 6         6           nữ 2. Nước ngoài         300000 200000000 3. mua xe chân 2 2.0 năm 2 khô nam 1.0 năm 1.0 việt Nam 700000 150000000 5. dâu tư cháng khoán học phố thống hón 5 nằm 32 hữu người vày có nợ xấu 3.20         0. Không nợ xấu 3.20         3. Trung học phố thống 10 khó ng nơ xấu 3.20         1. Thuộc số hữu người vày có nợ xấu 3.20         0. Không có nợ xấu 3.20         3. Trung học phố thống 10 khó ng vày có nợ xấu 3.20         1. Cô nơ xấu 3.20         3. 20         3. Trung học phố thống 10 khống có nợ xấu 3.20         3. 20         4. Khác 4         4           1. 1. Việt Nam Nam 140000 30000000 3. mua xe columns (to tal 15 columns):         2. Độc thần 1. 1 năm 17 thuộc số hữu người vày 1. Cô nơ xấu 3.20         1. Cô nơ xấu 3.20         3. 20         4. Khác 4         4           4 Column Columns (to tal 15 columns):         # Column 3.000 non-null int64         3000 non-null int64         3000 non-null int64         3000 non-null int64         3000 non-null int64           5 Mục đích vày         3000 non-null object         3000 non-null object         3000 non-null object         3000 non-null object           8 Tuổi         3000 non-null object         3000 non-null object         3000 non-null object         3000 non-null object           10 Nợ xấu         12 Khoảng cách đến điểm giao dịch gần nhất (km )         3000 non-null object

Comment: The data set used in the article includes 15 observation columns and 3000 rows. In which, there are 5 observation columns with integer data type and 10 observation columns with object data type. No missing data is found in the dataset.

#### 2.2. Step 2: Transform data

Code box 2.2. Transform data

Table 3\_ Code box 2.2. Transform data

```
# Convert data to numeric form
for i in df.columns:
    df[i] = df[i].astype(str).apply(lambda x: x.split('.')[0])
    df[i] = df[i].astype(str).apply(lambda x: x.split(':')[0])

# Convert data to integer
df = df.astype('int64')

# Check information and data format
df.info()
```

Code box result table 2.2: Data conversion

Table 4 Code box result table 2.2. Data conversion

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3000 entries, 0 to 2999
Data columns (total 15 columns):
# Column
                                                  Non-Null Count Dtype
--- -----
                                                  -----
                                                  3000 non-null int64
0 ID khách hàng
                                                  3000 non-null int64
   Giới tính
                                                  3000 non-null int64
    Quốc tịch
                                                  3000 non-null int64
3000 non-null int64
    Hóa đơn tiền điện
    Số tiền vay
   Mục đích vay
                                                  3000 non-null int64
6 Gia đình
                                                  3000 non-null int64
7
    Thời gian tại công việc hiện tại
                                                  3000 non-null int64
8 Tuổi
                                                  3000 non-null int64
9 Tài sản đảm bảo
                                                  3000 non-null int64
10 Nơ xấu
                                                  3000 non-null int64
11 Khoảng cách đến điểm giao dịch gần nhất ( km ) 3000 non-null int64
                                                  3000 non-null int64
12 Học vấn
13 Thời gian vay (tháng)
                                                  3000 non-null int64
14 Khả năng trả nợ
                                                  3000 non-null int64
dtypes: int64(15)
memory usage: 351.7 KB
```

Comment: The data has been successfully converted and formatted as integer data.

#### 2.3. Step 3: Check the data

## 2.3.1. Missing data

Based on the data table in step 1 and step 2, the dataset used in the report has no missing data. However, just to be sure, check again.

Code box 2.3. Check for missing data

Table 5 Code box 2.3. Check for missing data

```
# Calculate percentage of missing data
total = df.isnull().sum().sort_values(ascending=False)
percent = (df.isnull().sum()/df.isnull().count()).sort_values(ascending=False)

# Missing percentage= number of missing lines / total number of lines.
missing_data = pd.concat([total, percent], axis=1, keys=["Total', 'Percent'])
missing_data
```

Code box result table 2.3: Check for missing data

Table 6 Code box result table 2.3: Check for missing data

Total   Percent
Giới tính   0   0.0     Quốc tịch   0   0.0     Hóa đơn tiền điện   0   0.0     Số tiền vay   0   0.0     Mục đích vay   0   0.0     Gia đình   0   0.0     Thời gian tại công việc hiện tại   0   0.0     Tuổi   0   0.0     Tai sản đảm bảo   0   0.0     Nợ xấu   0   0.0     Khoảng cách đến điểm giao dịch gần nhất (km)   0   0.0
Quốc tịch         0         0.0           Hóa đơn tiền điện         0         0.0           Số tiền vay         0         0.0           Mục đích vay         0         0.0           Gia đình         0         0.0           Thời gian tại công việc hiện tại         0         0.0           Tuổi         0         0.0           Tai sản đảm bảo         0         0.0           Nợ xấu         0         0.0           Khoảng cách đến điểm giao dịch gần nhất (km)         0         0.0
Hóa đơn tiền điện       0       0.0         Số tiền vay       0       0.0         Mục đích vay       0       0.0         Gia đình       0       0.0         Thời gian tại công việc hiện tại       0       0.0         Tuổi       0       0.0         Tài sản đảm bảo       0       0.0         Nợ xấu       0       0.0         Khoảng cách đến điểm giao dịch gần nhất (km)       0       0.0
Số tiền vay         0         0.0           Mục đích vay         0         0.0           Gia đình         0         0.0           Thời gian tại công việc hiện tại         0         0.0           Tuổi         0         0.0           Tài sản đảm bảo         0         0.0           Nợ xấu         0         0.0           Khoảng cách đến điểm giao dịch gần nhất (km)         0         0.0
Mục đích vay         0         0.0           Gia đình         0         0.0           Thời gian tại công việc hiện tại         0         0.0           Tuổi         0         0.0           Tài sản đảm bảo         0         0.0           Nợ xấu         0         0.0           Khoảng cách đến điểm giao dịch gần nhất (km)         0         0.0
Gia đình         0         0.0           Thời gian tại công việc hiện tại         0         0.0           Tuổi         0         0.0           Tài sản đảm bảo         0         0.0           Nợ xấu         0         0.0           Khoảng cách đến điểm giao dịch gần nhất (km)         0         0.0
Thời gian tại công việc hiện tại         0         0.0           Tuổi         0         0.0           Tài sản đảm bảo         0         0.0           Nợ xấu         0         0.0           Khoảng cách đến điểm giao dịch gần nhất (km)         0         0.0
Tuổi         0         0.0           Tài sản đảm bảo         0         0.0           Nợ xấu         0         0.0           Khoảng cách đến điểm giao dịch gần nhất (km)         0         0.0
Tài sản đảm bảo         0         0.0           Nợ xấu         0         0.0           Khoảng cách đến điểm giao dịch gần nhất (km)         0         0.0
$\label{eq:Normalization} N \sigma  x \\ \text{$a$u} \qquad 0 \qquad 0.0$ Khoảng cách đến điểm giao dịch gần nhất ( km )  0  0.0
Khoảng cách đến điểm giao dịch gần nhất ( km ) 0 0.0
Học vấn 0 0.0
Thời gian vay (tháng) 0 0.0
Khả năng trả nợ 0 0.0

Comment: The dataset used in the article certainly has no missing data.

#### 2.3.2. Abnormal data

According to the regulations of the State Bank of Vietnam, the minimum age to borrow credit is 18 years old for each individual, so it will be checked if there are customers under 18 years old in the data set used, or not.

#### Code box 2.4. Check for invalid data

Table 7 Code box 2.4. Check for invalid data

```
# Check if the dataset has customers under 18 years old

df_18 = df[df['Tuổi'] <= 18]

df_18
```

#### Code box results box 2.4: Check invalid data

Table 8 Code box results box 2.4: Check invalid data

	ID khách hàng	Giới tính	Quốc tịch	Hóa đơn tiền điện	Số tiền vay	Mục đích vay	Gia đình	Thời gian tại công việc hiện tại	Tuổi	Tài sản đảm bảo	Nợ xấu	Khoảng cách đến điểm giao dịch gần nhất ( km )	Học vấn	Thời gian vay (tháng)	Khả năng trả nọ
4	5	1	1	140000	300000000	3	2	1	17	0	1	3	4	4	1
52	53	1	1	264000	167400000	3	2	1	17	0	1	3	4	4	1
89	90	1	1	608000	396400000	3	2	1	17	0	1	3	4	4	1
137	138	1	1	416000	172000000	3	2	1	17	0	1	3	4	4	1
204	205	1	1	592000	462900000	3	2	1	17	0	1	3	4	4	1
2782	2783	1	1	504000	376100000	3	2	1	17	0	1	3	4	4	C
2830	2831	1	1	592000	485100000	3	2	1	17	0	1	3	4	12	1
2865	2866	1	1	432000	460600000	5	2	1	17	0	1	3	2	4	1
2913	2914	1	1	648000	324900000	3	2	1	17	0	0	4	4	4	C
2980	2981	1	1	304000	135500000	3	2	1	17	0	0	2	4	6	(

Comment: There are 66 customers under the age of 18, not in accordance with regulations. So the decision was made to remove these customers from the data.

#### Code box 2.5. Get valid data

Table 9 Code box 2.5. Get valid data

```
# Get qualified customer data

df = df[df['Tuổi'] > 18]

df

# Check remaining data percentage

print('Dữ liệu khách hàng còn lại sau khi loại bỏ những khách hàng không đủ điều kiện là:',

df.shape[0]/df_test.shape[0]*100 ,'%')
```

#### Code box result 2.5: Get valid data

Table 10 Code box result box 2.5: Get valid data

#### Kết quả:

Dữ liệu khách hàng còn lại sau khi loại bỏ những khách hàng không đủ điều kiện là: 97.8 %

#### 2.3.3. Check outliers data

Outliers need to be identified and eliminated as this is an extremely important step in data processing. The processing of outliers will greatly increase the accuracy of predictive models or business reports. If outliers are detected in the dataset, it will depend on the distribution of the dataset to use a reasonable method (IQR, Z-score, STD ...). In the dataset, the observed variables "Hóa đơn tiền điện", Số tiền vay", "Tuổi" và "Thời gian vay" are in the form of quantitative data, the remaining data is classified or binary data, because so will only check the outliers of the above four observations using boxplot.

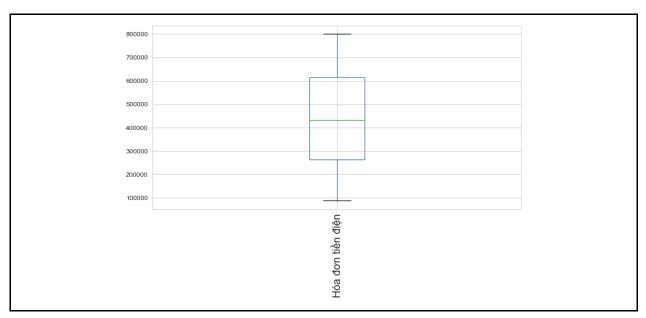
Code box 2.6. Check outliers data

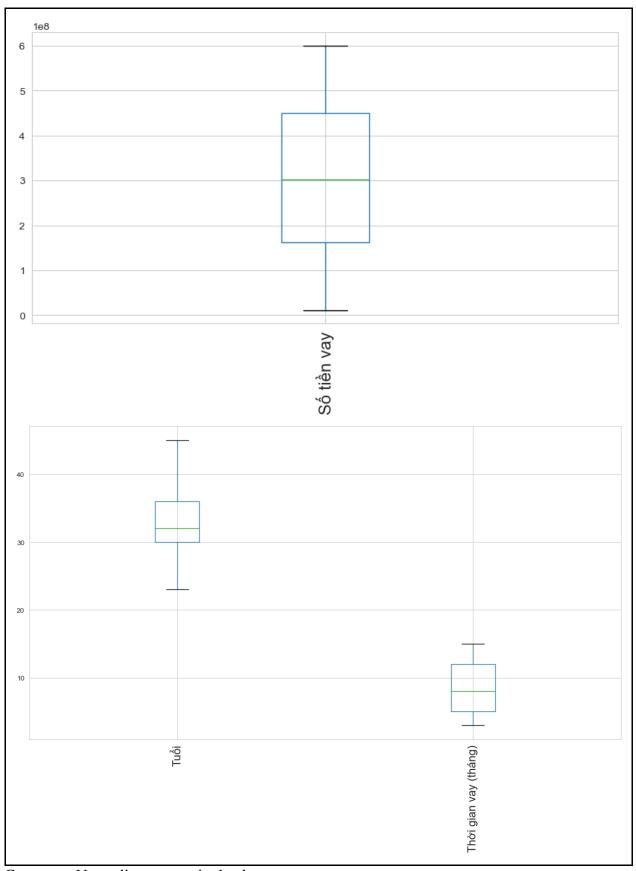
Table 11 Code box 2.6. Check outliers data

```
# Boxplot
# Hóa don tiền điện
boxplot = df.boxplot(column=['Hóa đơn tiền điện'], figsize=(10,5), rot=90)
boxplot.tick_params(axis='x', labelsize=16)
# Số tiền vay
boxplot = df.boxplot(column=['Số tiền vay'],figsize=(10,5), rot=90)
boxplot.tick_params(axis='x', labelsize=16)
# Tuổi và Thời gian vay
boxplot = df.boxplot(column=['Tuổi','Thời gian vay (tháng)'], figsize=(15,8), rot=90)
boxplot.tick_params(axis='x', labelsize=16)
```

Result table of code box 2.6: Check outlier data

Table 12 Result table of code box 2.6: Check outlier data





Comment: No outliers appear in the dataset.

# 2.4. Step 4: Descriptive Statistics

## 2.4.1. Statistical index

## Code box 2.7. Statistical index

Table 13 Code box 2.7. Statistical index

df.describe().drop(columns=['ID khách hàng'])

Code box result table 2.7: Statistical index

Table 14 Code box result table 2.7: Statistical index

Kết qu	ıå:											
	Giới	tính	Quốc tị	ch	Hóa đơn t đ	tiên liện	Số tiền v	vay	Mục đíc va	Gia di	ình	Thời gian tại công việc hiện tại
count	2934.00	0000	2934.0000	00	2934.000	000	2.934000e-	+03	2934.00000	0 2934.0000	000	2934.000000
mean	1.52	4540	1.1366	73	439477.164	281	3.058056e-	+08	3.06066	1.8810	)50	3.758010
std	0.49	9483	0.3435	61	205596.496	872	1.692276e-	+08	1.30031	9 0.7958	305	1.171631
min	1.00	0000	1.0000	00	88000.000	000	1.120000e-	+07	1.00000	00 1.0000	000	1.000000
25%	1.00	0000	1.0000	00	264000.000	000	1.615500e-	+08	2.00000	00 1.0000	000	3.000000
50%	2.00	0000	1.0000	00	432000.000	000	3.021500e-	+08	3.00000	00 2.0000	000	4.000000
75%	2.00	0000	1.0000	00	616000.000	000	4.500000e-	+08	4.00000	00 3.0000	000	5.000000
max	2.00	0000	2.0000	00	800000.000	000	6.000000e-	+08	5.00000	3.0000	000	5.000000
	Tuổi	Tài s	sản đảm bảo		Nợ xấu	đ	Khoảng cách đến liểm giao dịch gần nất ( km )		Học vấn	Thời gia vay (tháng		Khả năng trả nợ
2934.0	000000	2934	1.000000	293	4.000000	293	34.000000	293	34.000000	2934.00000	0	2934.000000
33.2	294479	C	).670416		0.390593		2.589639		2.585549	7.88275	4	0.291411
5.3	350312	C	).470142		0.487966		0.993316		1.153720	3.89959	5	0.454490
23.0	000000	C	0.000000		0.000000		1.000000		1.000000	3.00000	0	0.000000
30.0	000000	C	0.000000		0.000000		2.000000		2.000000	5.00000	0	0.000000
32.0	000000	1	.000000		0.000000		2.000000		2.000000	8.00000	0	0.000000
36.0	000000	1	.000000		1.000000		3.000000		4.000000	12.00000	0	1.000000
45.0	000000	1	.000000		1.000000		4.000000		4.000000	15.00000	0	1.000000

#### 2.4.2. The degree of correlation between variables

Code box 2.8. Check the degree of correlation between variables

Table 15 Code box 2.8. Check the degree of correlation between variables

```
# correlation

df_corr = pd.DataFrame(df.corr().iloc[1:,-1]).drop(index=['Khả năng trả nợ'])

df_corr

# Plot

ax = df_corr.plot.barh(figsize=(8, 6))

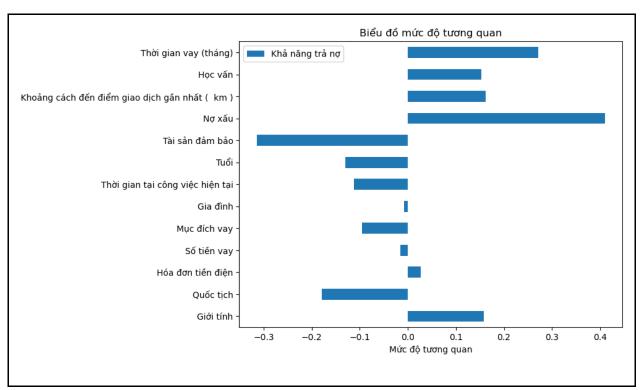
ax.set_xlabel('Mức độ tương quan')

ax.set_title('Biểu đồ mức độ tương quan')

plt.show()
```

Code box result table 2.8: Check the degree of correlation between variables

Table 16 Code box result table 2.8: Check the degree of correlation between variables



Comment: The variables that have the most correlation with the target variable are Loan duration, Bad debt (positive correlation) and collateral (negative correlation), in addition, at least family, loan amount and electricity bills.

## 2.5. Step 5: Visualization

## 2.5.1. Data distribution of quantitative variables

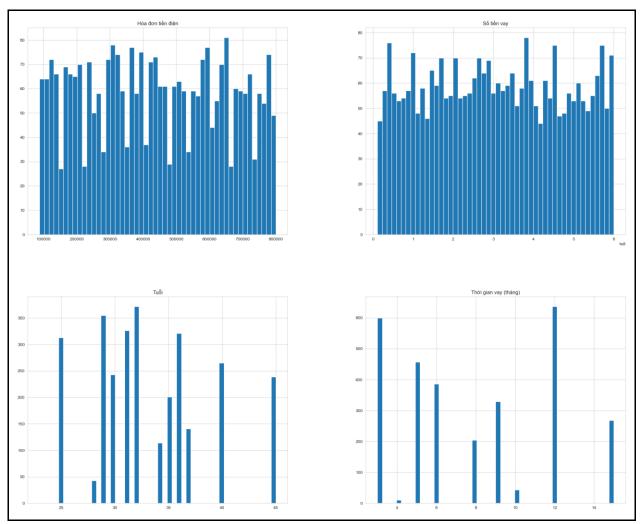
Code box 2.9. Data distribution

Table 17 Code box 2.9. Data distribution

```
%matplotlib inline
# Plot
df.hist(column=['Hóa đơn tiền điện','Số tiền vay','Tuổi','Thời gian vay (tháng)'],bins=50,
figsize=(25,20))
plt.show()
```

Code box result table 2.9: Data distribution

Table 18 Code box result table 2.9: Data distribution



Comment: In the observation of the electricity bill and the loan amount of the customer, the distribution of the amount does not skew towards more or less, in which the amount of electricity bill is in the range (100 - 800 thousand VND), and the loan amount is in the range (100 - 600

million VND). The age group of customers is concentrated mainly in the range of 30 to 40 years old, and the credit loan period ranges from 2 to 15 months, with the largest number of customers taking out loans for 12 months. All observations are not normally distributed.

#### 2.5.2. Visualize layered data and target variables

Code box 2.10. Checking customer's ability to repay debt by gender

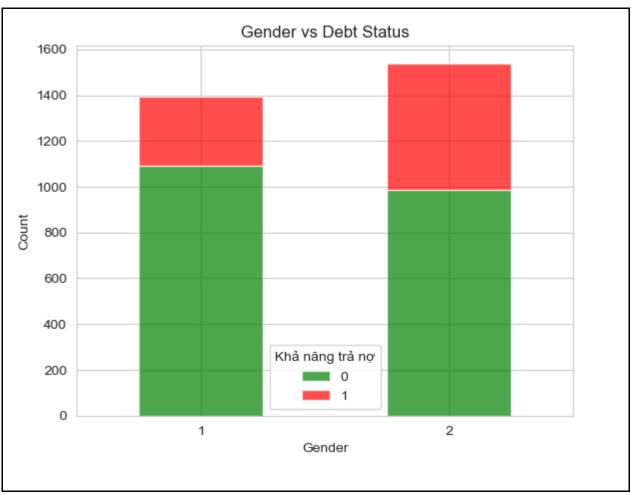
Table 19 Code box 2.10. Checking customer's ability to repay debt by gender

```
# Groupby data by condition
gender_debt = df.groupby(['Khå năng trả nợ','Giới tính']).agg( Count = ( 'Giới tính','count'
)).reset_index()
gender_debt
# Create pivot table to reformat data
pivot = pd.pivot_table(gender_debt, values='Count', index='Giói tính', columns='Khå năng trả
nợ')
# Barplot
pivot.plot(kind='bar', stacked=True, color=['green', 'red'], alpha=0.7)
# Set title, axis label
plt.title('Gender vs Debt Status')
plt.xlabel('Gender')
plt.ylabel('Count')
# Format x-axis
plt.xticks(np.arange(len(pivot.index)), pivot.index, rotation=0)
# Show chart
plt.show()
```

Code box result table 2.10: Checking customer's ability to repay debt by gender

Table 20 Code box result table 2.10: Checking customer's ability to repay debt by gender

Khả năng trả nợ       0       1         Giới tính       1       1094       301         2       985       554	M - 3 4 - 3 1	^	
1 1094 301	Kha nang tra nợ	U	1
	Giới tính		
2 985 554	1	1094	301
	2	985	554



Comment: The number of male and female customers is not much different, the number of male customers is less than female customers. The number of male customers paying on time is more than the number of female customers, namely 1094 male customers compared to 985 female customers. In addition, the number of female customers who do not pay on time is more than the number of male customers, namely 554 female customers compared to 301 male customers.

#### 2.5.3. Visualize the amount of data in the observed variables

Code box 2.11. Amount of data in observed variables

Table 21 Code box 2.11. Amount of data in observed variables

```
# countplot

sns.set_style('whitegrid') # set style for plot

fig, axes = plt.subplots(nrows=5, ncols=2, figsize=(25, 20)) # create a grid 4x2 plot

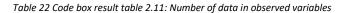
sns.countplot(x='Giới tính', data=df, ax=axes[0,0])

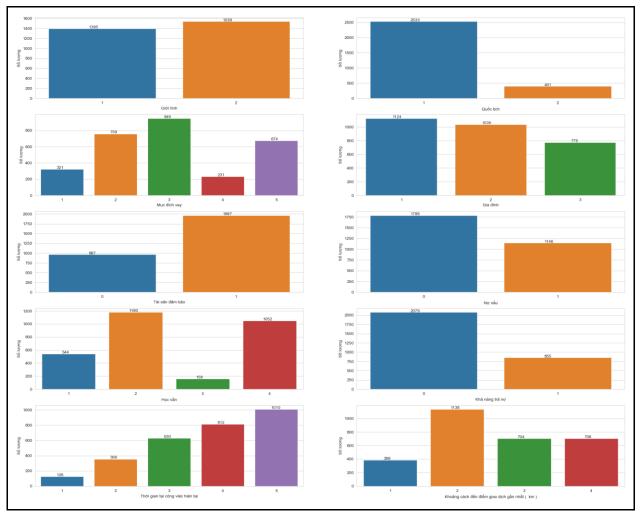
axes[0,0].set_ylabel('Số lượng')
```

```
for p in axes[0,0].patches:
    axes[0,0].annotate(p.get_height(), (p.get_x()+0.3, p.get_height()+5))

sns.countplot(x='Quốc tịch', data=df, ax=axes[0,1])
axes[0,1].set_ylabel('Số lượng')
for p in axes[0,1].patches:
    axes[0,1].annotate(p.get_height(), (p.get_x()+0.3, p.get_height()+5))
......
plt.show()
```

Code box result table 2.11: Number of data in observed variables





Comment: The data shows that out of a total of 2934 customers, there are 1395 male customers and 1539 female customers, of which 401 customers are foreign nationals and 2533 customers are Vietnamese. The main purpose of the customer's loan is to buy personal property. The total number of single customers is 1124, married is 1035 and the rest is divorced with 775 customers. Most of

the client's collateral is owned by themselves, and most of the clients have no bad debt, with 1788 clients having no bad debt. The most common client education is a university degree, and most clients have been in their current job for more than 4 years.

## 2.6. Step 6: Prepare data for the model

#### 2.6.1. Check target variable

Code box 2.12. Check target variable

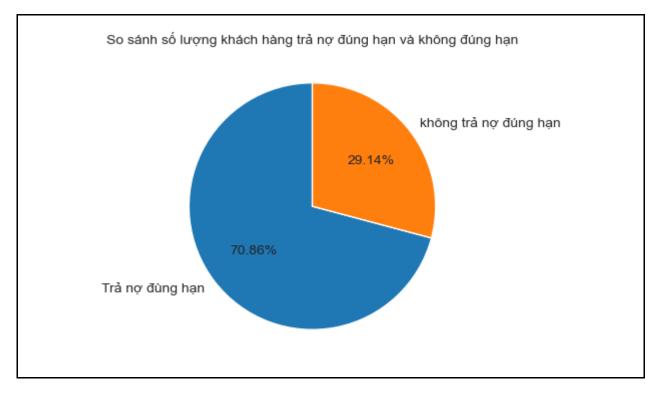
Table 23 Code box 2.12. Check target variable

```
# Debt repayment comparison chart df_dept = df['Khå năng trả nợ'].value_counts()

fig, ax = plt.subplots(figsize=(6, 4))
ax.pie(df_dept, labels=['Trả nợ đùng hạn','không trả nợ đúng hạn'], autopct='%2.2f%%', startangle=90)
plt.title("So sánh số lượng khách hàng trả nợ đúng hạn và không đúng hạn", size =10)
plt.show()
```

Code result table 2.12: Check target variable

Table 24 Code result table 2.12: Check target variable



Comment: The current data are unbalanced, since the number of samples of class 1 is significantly less than that of class 0 (70.86% and 29.14%). So, to solve this problem, oversampling method is suitable to solve this problem. Oversampling is used to increase the sample size for the minority class.

#### Code box 2.13. Data balance

Table 25 Code box 2.13. Data balance

#### Code box result table 2.13: Data balance

Table 26 Code box result table 2.13: Data balance

```
0 2079
1 2079
Name: Khả năng trả nợ, dtype: int64
```

Comment: The data has been balanced with a count of 2079 for both forecast classes.

#### 2.6.2. Prepare data for the model

Code box result table 2.14. Prepare forecast data for the model

Table 27 Code box result table 2.14. Prepare forecast data for the model

```
# Select target variable
target = ['Khå năng trå nợ']
features = list(set(list(balanced_data.columns)) - set(target))

# Balance data
balanced_data = balanced_data.drop(columns=['ID khách hàng'])
X = balanced_data[features].values
y = balanced_data[target].values
```

```
# Unbalanced data
df = df.drop(columns=['ID khách hàng'])

X_ = balanced_data[features].values
y_ = balanced_data[target].values
```

Code box 2.15: Normalize data

Table 28 Code box 2.15: Normalize data

```
# Balanced data normalization
scaler = StandardScaler()
X = scaler.fit_transform(X)

# Unbalanced data normalization
scaler = StandardScaler()
X_ = scaler.fit_transform(X_)
```

#### 2.7. Step 7: Run and read model results with Decision Tree

#### 2.7.1. Compare Decision Tree results with unbalanced and unbalanced data

Code box 2.16. Run and read model results with Decision Tree (unbalanced data)

Table 29 Code box 2.16. Run and read model results with Decision Tree (unbalanced data)

```
# Chia tập dữ liệu

X_ = df[features].values
y_ = df[target].values
X_train, X_test, y_train, y_test = train_test_split(X_, y_, test_size = 0.1, random_state=42)

# Chạy mô hình

DT_classifier = DecisionTreeClassifier()

DT_classifier.fit(X_train, y_train.ravel())

y_pred = DT_classifier.predict(X_test)
print(confusion_matrix(y_test,y_pred))
print(classification_report(y_test,y_pred))
print('Decision Tree accuracy: ', accuracy_score(y_test, y_pred))
```

Code box results table 2.16: Run and read model results with Decision Tree (unbalanced data)

[[184 25] [ 23 62]]	precision	recall	f1-score	support	
	p				
0	0.89	0.88	0.88	209	
1	0.71	0.73	0.72	85	
accuracy			0.84	294	
macro avg	0.80	0.80	0.80	294	
weighted avg	0.84	0.84	0.84	294	
Decision Tre	e accuracy:	0.8367346	938775511		

Code box 2.17. Run and read model results with Decision Tree (balanced data)

Table 31 Code box 2.17. Run and read model results with Decision Tree (balanced data)

```
# Split dataset
X = balanced_data[features].values
y = balanced_data[target].values
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.1, random_state=42)

# Run the model
DT_classifier = DecisionTreeClassifier()
DT_classifier.fit(X_train, y_train.ravel())

y_pred = DT_classifier.predict(X_test)
print(confusion_matrix(y_test,y_pred))
print(classification_report(y_test,y_pred))
print('Decision Tree accuracy: ', accuracy_score(y_test, y_pred))
```

# Code box results table 2.17: Run and read model results with Decision Tree (balanced data)

Table 32 Code box results table 2.17: Run and read model results with Decision Tree

[[202 29] [ 7 178]]			6.		
	precision	recall	f1-score	support	
0	0.97	0.87	0.92	231	
1	0.86	0.96	0.91	185	
accuracy			0.91	416	
macro avg	0.91	0.92	0.91	416	
weighted avg	0.92	0.91	0.91	416	
Decision Tree	accuracy:	0.9134615	384615384		

#### Comment:

Comparing two confusion matrices on balanced and unbalanced data we have:

The confusion matrix on the unbalanced data shows that the Decision Tree model correctly predicted 246 out of 294 samples, equivalent to an accuracy rate of 83.7%. In which, the number of incorrect predictions is the number of samples belonging to the class of false positives with 25 cases. This can be explained by the lack of balance between the two data classes, making it easy for the model to predict many patterns of the class that are not present in the data set. The confusion matrix on the balanced data shows that the Decision Tree model correctly predicted 380 out of 416 samples, equivalent to an accuracy rate of 91.3%. The correct ratio of the model on balanced data is much higher than on unbalanced data, showing that data balance is very important in model building. The model's most false prediction on balanced data is the number of samples belonging to the false negative class with 7 cases, but this number has fallen sharply compared to the unbalanced data.

Table 2.1: comparing the results of Decision Tree on 2 data sets

Table 33 Table 2.1: Comparing the results of Decision Tree on 2 data sets

Score	Imbalance	Balance
Accuracy	0.837	0.913
Precision của lớp 0	0.89	0.97
Recall của lớp 0	0.88	0.87
F1-score của lớp 0	0.88	0.92
Precision của lớp 1	0.71	0.86
Recall của lớp 1	0.73	0.96
F1-score của lớp 1	0.72	0.91

On balanced data, the Decision Tree model achieves high accuracy (0.913) and the F1-scores of both classes are high (0.92 and 0.91). Both of these metrics are higher than on unbalanced data (accuracy is 0.837 and F1-scores for classes 0 and 1 are 0.88 and 0.72, respectively).

Precision of class 0 on balanced data achieved very good results (0.97), while on unbalanced data achieved only 0.89. Precision of class 1 on balanced data is also higher (0.86) than on unbalanced data (0.71).

Class 0's recall on balanced and unbalanced data is quite close (0.87 and 0.88), while class 1's recall on balanced data achieves very high results (0.96) and increases compared to lossy data. balanced (0.73). Conclusion: Using balanced data helps the Decision Tree model to achieve higher accuracy and better classification for both classes. However, to evaluate the effectiveness of the model, it is necessary to consider other indicators such as AUC, ROC curve, and Confusion Matrix.

Conclusion: Using balanced data helps Decision Tree model to achieve higher accuracy and better classifier for both classes.

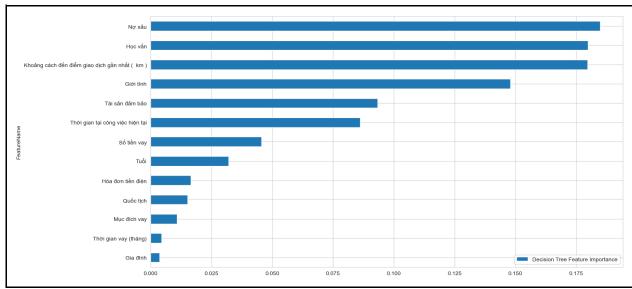
#### 2.7.2. Important variables for Decision Tree

Code box 2.18. Find variables with strong influence on Decision Tree

Table 34 Code box 2.18. Find variables with strong influence on Decision Tree

```
# Find important variables
importance_dt = DT_classifier.feature_importances_
features_importances_dt = pd.DataFrame({ 'FeatureName':
    balanced_data.columns[0:len(balanced_data.columns)-1], 'Decision Tree Feature Importance':
    importance_dt})
features_importances_dt.sort_values(by=['Decision Tree Feature Importance'],
    ascending=False)
# Plot
features_importances_dt.sort_values("Decision Tree Feature Importance").plot(figsize=(15,8),
    x="FeatureName", y=["Decision Tree Feature Importance"], kind="barh")
```

Code box results table 2.18: Run and read model results with Decision Tree (balanced data)



Comment: The variables of the data set used in the report that have the most influence on the forecast results of Decision Tree are bad debt, education, distance to the nearest transaction point, gender, financial position, etc. guarantee and time at current job. This means that, if we only use these variables for the Decision Tree model, we can improve the prediction results.

#### 2.7.3. Decision Tree's ROC\_Curve

Code box 2.19. Plot Decision Tree's ROC\_Curve

Table 36 Code box 2.19. Plot Decision Tree's ROC\_Curve

```
from sklearn.metrics import roc_curve, auc

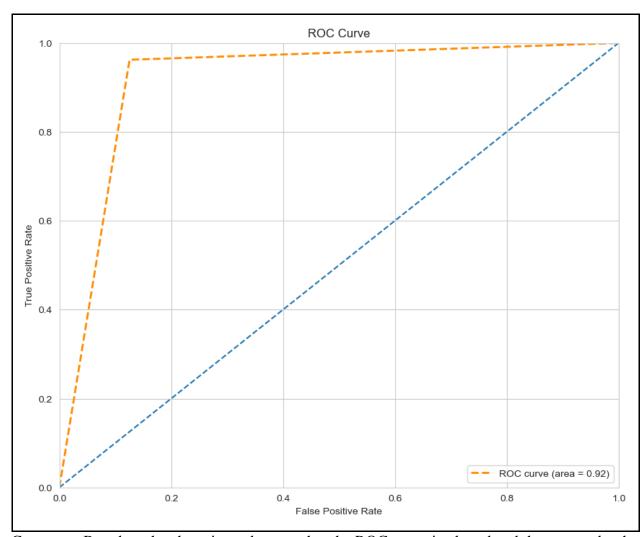
def _plot_roc_curve(fpr, tpr, thres, auc):
    plt.figure(figsize = (10, 8))
    plt.plot(fpr, tpr, 'b-', color='darkorange', lw=2, linestyle='--', label='ROC curve (area = %0.2f)'% auc)
    plt.plot([0, 1], [0, 1], '--')
    plt.axis([0, 1, 0, 1])
    plt.xlabel('False Positive Rate')
    plt.ylabel('True Positive Rate')
    plt.legend(loc='lower right')
    plt.title('ROC Curve')

y_pred_prob_test = DT_classifier.predict_proba(X_test)[:, 1]
fpr, tpr, thres = roc_curve(y_test, y_pred_prob_test)
roc_auc = auc(fpr, tpr)

_plot_roc_curve(fpr, tpr, thres, roc_auc)
```

# Code box result table 2.19: Plot Decision Tree's ROC\_Curve

Table 37 Code box result table 2.19: Plot Decision Tree's ROC\_Curve



Comment: Based on the chart, it can be seen that the ROC curve is plotted and the area under the ROC curve is 0.92. This shows that the classification model has a good performance, as the area under the ROC curve is between 0.5 and 1.0 and the closer to 1, the better the model. So Decision Tree has good classification ability.

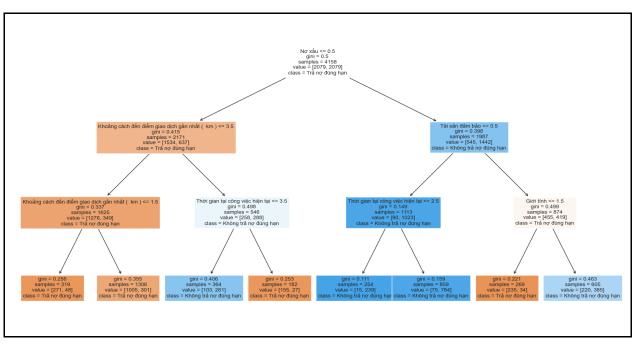
#### Code box 2.20. Plot Tree

Table 38 Code box 2.20. Plot Tree

```
# Check target variable definition
balanced_data['Khå năng trả nơ'].unique()
# Select input variables and output variables
X_tree = balanced_data[['No xấu','Học vấn','Khoảng cách đến điểm giao dịch gần nhất (km
)','Giới tính','Tài sản đảm bảo','Thời gian tại công việc hiện tại']]
y_tree = balanced_data['Khå năng trả nơ']
# Name of input variables
features = ['Nợ xấu','Học vấn','Khoảng cách đến điểm giao dịch gần nhất (km)','Giới tính','Tài
sản đảm bảo', 'Thời gian tại công việc hiện tại']
# Create a Decision Tree classifier with selected variables
clf = DecisionTreeClassifier(max_depth=3)
# Train the model with input data and output labels
clf.fit(X_tree, y_tree)
# Plot decision tree
plt.figure(figsize=(20,10))
plot_tree(clf, fontsize=10, filled=True, feature_names=features, class_names=["Trå no dung
hạn", "Không trả nợ đúng hạn"])
plt.show()
```

#### Code box result table 2.20: Plot Tree

Table 39 Code box result table 2.20: Plot Tree



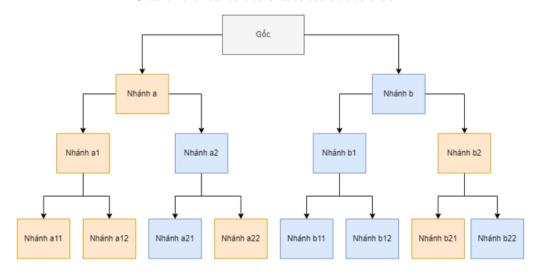


Chart 2.1. Name the branches in the tree

Figure 2 Chart 2.1. Name the branches in the tree

Comment: This decision tree has a root with the following information: Bad debt  $\leq 0.5$ , gini = 0.5, samples = 4158, values = [2079, 2079].

This root has two branches, branch a and branch b. Branch a is divided from the root with the criteria being Distance to the nearest transaction point <= 3.5, gini = 0.415, samples = 2171, value = [1543, 637], Class = On-time repayment. This branch is again divided into two sub-branches, branch a1 and a2. Branch a1 is divided into two sub-branches, branch a11 and a12. Branch a2 is also divided into two sub-branches, branch a21 and a22.

Branch b is divided from the root with the criteria as collateral <= 0.5, gini = 0.398, samples =1987, values = [545, 1442], class = default. This branch is again divided into two sub-branches, branch b1 and b2. Branch b1 is again divided into two sub-branches, branch b2 is divided into two sub-branches, branch b21 and b22.

Each sub-branch will have a gini index to evaluate the categorization of the data in that sub-branch. The lower the gini index, the better the classification of the data in that sub-branch. For branching, the decision tree uses different criteria.

Example of tree operation: At the root, the decision tree is branched into two sub-branches a and b based on the bad debt criterion <= 0.5. Branch a is further branched into two sub-branches a1 and a2 based on the criteria of distance to the nearest transaction point and gini index value. Branch a1 has a lower gini index value than branch a2, indicating a more accurate classification for the data group in branch a1. Therefore, the decision tree will continue to branch at a1 to create two sub-branches a11 and a12 based on the criteria of distance to nearest transaction point and gini index value. In branch a11, the gini index value is even lower than in branch a12, indicating a more accurate classification for the data group in branch a11. Therefore, the decision tree will continue

to branch at all to produce further sub-branches. So, from root to all and from all to all are both based on the gini index value and the distance criterion to the nearest transaction point to optimize the ability to classify correctly for data groups.

#### 2.8. Step 8: Run and read model results with Random Forest

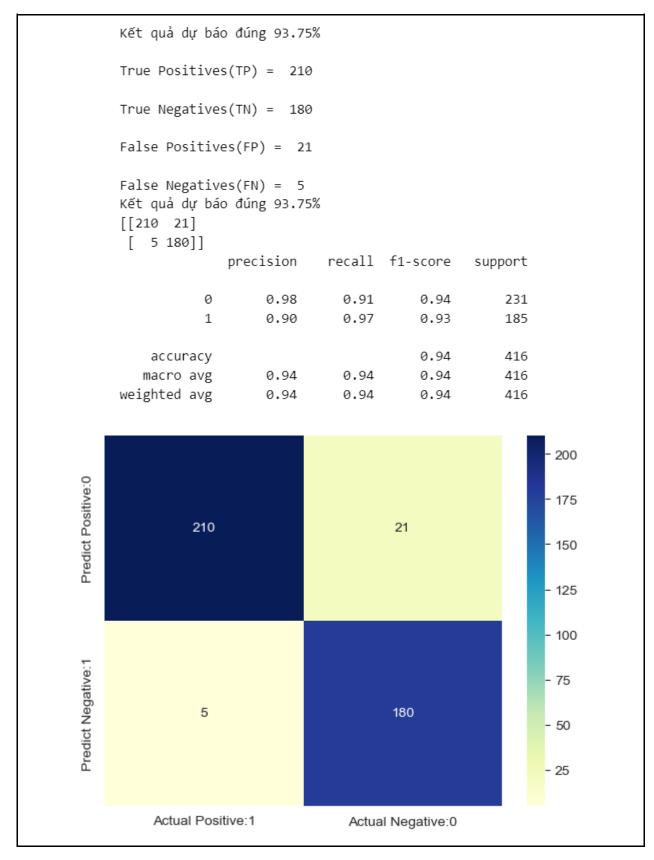
#### 2.8.1. Run and read model results with Random Forest

Code box 2.21. Run and read forecasts with Random Forest

Table 40 Code box 2.21. Run and read forecasts with Random Forest

```
RF classifier = RandomForestClassifier()
RF_classifier.fit(X_train, y_train.ravel())
y_pred = RF_classifier.predict(X_test)
print(confusion_matrix(y_test,y_pred))
print(classification report(y test,y pred))
print('Random Forest accuracy: ', accuracy_score(y_test, y_pred))
cm = confusion_matrix(y_test, predictions)
print("Kết quả dư báo đúng {0:.2f}%".format(100*accuracy score(predictions, y test)))
print(\n True\ Positives(TP) = ', cm[0,0])
print("Kết quả dự báo đúng {0:.2f}%".format(100*accuracy_score(predictions, y_test)))
print(confusion_matrix(y_test, predictions))
print(classification_report(y_test, predictions))
. . . . . .
cm matrix = pd.DataFrame(data=cm, columns=['Actual Positive:1', 'Actual
Negative:0'],index=['Predict Positive:0', 'Predict Negative:1'])
sns.heatmap(cm_matrix, annot=True, fmt='d', cmap='YlGnBu')
```

Code box result table 2.21: Run and read forecast results with Random Forest



Comment: Compared with the results of the Random Forest model, the results of the decision tree model with balanced data have lower accuracy. The decision tree model with balanced data has an accuracy of 0.913, while your Random Forest model has a higher accuracy of 0.9375. In addition, your Random Forest model has a higher precision and recall of class 1 than the decision tree model with balanced data. In general, the Random Forest model has better results than the decision tree model with balanced data.

#### 2.8.2. Important variables with Random Forest

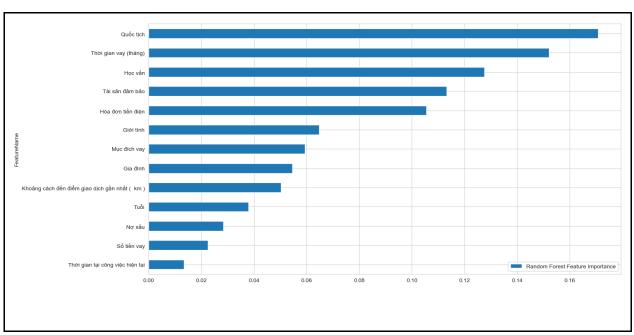
Code box 2.22. Important Variables Random Forest

Table 42 Code box 2.22. Important Variables Random Forest

```
# Tìm kiếm các biến quan trọng
importance_rf = RF_classifier.feature_importances_
features_importances_rf = pd.DataFrame({'FeatureName':
balanced_data.columns[0:len(balanced_data.columns)-1], 'Random Forest Feature Importance':
importance_rf})
features_importances_rf.sort_values(by=['Random Forest Feature Importance'],
ascending=False)
# Vẽ biểu đồ
features_importances_rf.sort_values("Random Forest Feature Importance").plot(figsize=(15,8),
x="FeatureName", y=["Random Forest Feature Importance"], kind="barh")
```

#### Code box results table 2.22: Important Variables Random Forest

Table 43 Code box results table 2.22: Important Variables Random Forest



Comment: In Decision Tree, the variables Bad debt, education, distance to the nearest transaction point, gender, collateral and time at current job were determined to have the highest influence on forecast results. Meanwhile, in Random Forest, the variables Nationality, Borrowing period, Education, Collateral, Electricity bill and Gender are identified as having the greatest influence on the forecast results. These variables can be used to improve the prediction results of the Random Forest model.

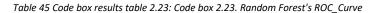
## 2.8.3. Random Forest's ROC\_Curve

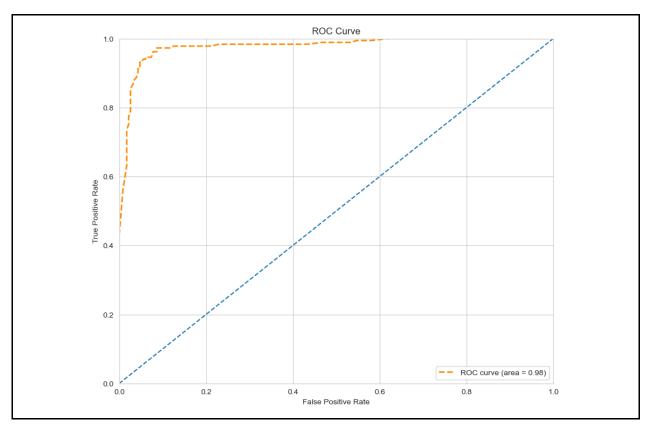
Code box 2.23. Random Forest's ROC\_Curve

Table 44 Code box 2.23. Random Forest's ROC\_Curve

```
y_pred_prob_test = RF_classifier.predict_proba(X_test)[:, 1]
fpr, tpr, thres = roc_curve(y_test, y_pred_prob_test)
roc_auc = auc(fpr, tpr)
_plot_roc_curve(fpr, tpr, thres, roc_auc)
```

Code box results table 2.23: Code box 2.23. Random Forest's ROC\_Curve





Comment: Comparing the roc\_curve results of the Random Forest model and the Decision Tree model, we see that the Random Forest model has a higher area value of 0.98 than the Decision Tree model's value of 0.92. This shows that the Random Forest model has a good ability to classify True Positive and True Negative cases and has higher accuracy than Decision Tree.

#### 2.9. Step 9: New customer forecast with used data set

Code box 2.24. Generate new customer data and forecasts

Table 46 Code box 2.24. Generate new customer data and forecasts

```
# Tạo dữ liệu khách hàng mới
sample_test = [1, 1, 900000, 450000000, 4, 1, 2, 30, 1, 0, 2, 2, 6]
# Thực hiện dự báo
prediction = RF_classifier.predict([sample_test])[0]
# Câu lệnh điều kiện
if prediction == 0:
    print("Khách hàng trả trợ đúng hạn.")
else:
    print("Khách hàng trả nợ không đúng hạn.")
```

Code box results table 2.23: Run and read forecast results with Random Forest

Table 47 Code box results table 2.23: Run and read forecast results with Random Forest

Khách hàng trả trợ đúng hạn.

Comments: New customer data can be introduced to enable forecasting.

#### **III. Conclusion**

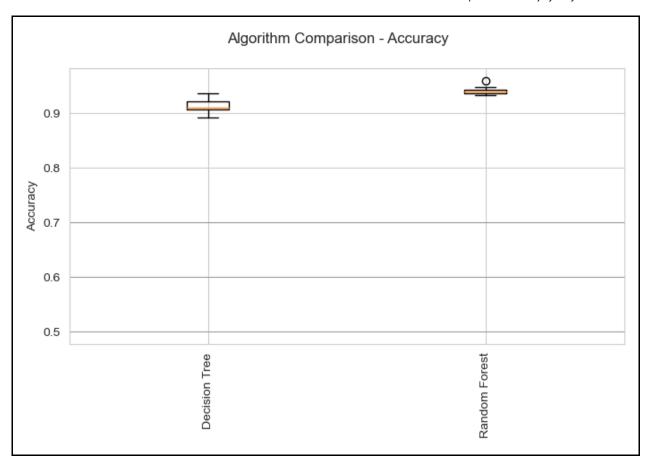
## Code box 3.1. Compare indicators between 2 forecasting models

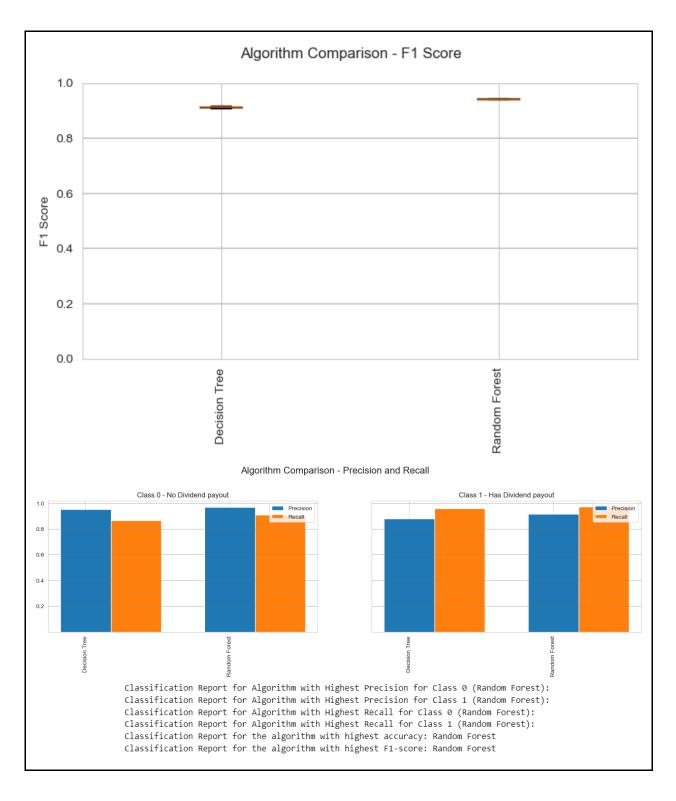
Table 48 Code box 3.1. Compare indicators between 2 forecasting models

```
models = [
 ('Decision Tree', DecisionTreeClassifier()),
 ('Random Forest', RandomForestClassifier()),]
results = []
names = []
reports = []
times = []
for name, model in models:
 kfold = KFold(n_splits=10, shuffle=True, random_state=42)
.....
# plot the performance of each algorithm using a box plot
fig1 = plt.figure(figsize=(8, 4))
fig1.suptitle('Algorithm Comparison - Accuracy')
.....
.....
# compute and plot the f1 score for each algorithm using a box plot
f1\_scores = []
for report in reports:
 f1_scores.append([report['0']['f1-score'], report['1']['f1-score']])
.....
.....
```

# Code box results table 3.1: Compare the stability of the forecast results

Table 49 Code box results table 3.1: Compare the stability of the forecast results





Comment: The forecast results of Random Forest are higher and more stable than that of Decision Tree. Based on the chart and the comparison results, all show that the results of Random Forest are better than Decision Tree. In addition, the results after analysis also show that normalizing the data, balancing the data and selecting the variables with influence will bring better forecasting results on the used data set.

Some limitations when doing this is that the data set is not close to reality, there are many variables that do not have a good influence on the model. The future development direction is that it is possible to add input variables affecting the customer's debt repayment ability, can use other forecasting models to be able to compare the efficiency and find the model that is consistent with the article. Furthermore, after developing the complete model, one can apply it in practice to evaluate the model's effectiveness and reliability in a real-world environment by creating web or applications. It can be used to make decisions about whether or not to grant a loan to a specific customer and track the results of the model over time so that improvements can be made.

# Github:

https://github.com/MiCasa0403001/credit-risk-model-in-R-Python

# **Reference documents**

Nguyễn Đức Thành, Lê Thanh Bình, Nguyễn Thị Ánh Tuyết, & Trần Đức Minh. (2018). Ứng dụng học máy trong dự báo tín dụng. NXB Giáo dục.